

第三讲-习题

姜帆

2019 年 7 月 14 日

目录

1	LM 算法	2
1.1	阻尼因子变化曲线图	2
1.2	更改曲线函数	3
1.3	Marquardt 阻尼因子更新策略	5
2	公式推导	6
2.1	f_{15}	6
2.2	g_{12}	7
3	证明	8

1 LM 算法

1.1 阻尼因子变化曲线图




图 1: 阻尼因子变化曲线图

下图为程序运行结果：

```

Test CurveFitting start...
iter: 0 , chi= 36048.3 , Lambda= 0.001
iter: 1 , chi= 30015.5 , Lambda= 699.051
iter: 2 , chi= 13421.2 , Lambda= 1864.14
iter: 3 , chi= 7273.96 , Lambda= 1242.76
iter: 4 , chi= 269.255 , Lambda= 414.252
iter: 5 , chi= 105.473 , Lambda= 138.084
iter: 6 , chi= 100.845 , Lambda= 46.028
iter: 7 , chi= 95.9439 , Lambda= 15.3427
iter: 8 , chi= 92.3017 , Lambda= 5.11423
iter: 9 , chi= 91.442 , Lambda= 1.70474
iter: 10 , chi= 91.3963 , Lambda= 0.568247
iter: 11 , chi= 91.3959 , Lambda= 0.378832
iter: 12 , chi= 91.3959 , Lambda= 0.252554
problem solve cost: 19.8676 ms
makeHessian cost: 13.7245 ms
-----After optimization, we got these parameters :
0.941842 2.09467 0.965537
-----ground truth:
1.0, 2.0, 1.0
save mu to txt!

```

图 2: 程序运行结果

1.2 更改曲线函数

将曲线函数改为 $y = ax^2 + bx + c$, 修改对应雅克比计算函数, 残差计算函数。另注意由于生成仿真数据时添加了均值为 0, 方差为 1 的噪声项, 噪声相对于数据较大, 因此对增加仿真数据量。

$y = ax^2 + bx + c$ 函数对应的雅克比计算函数 (导数) 为 $y' = x^2 + x + 1$

```

1  class CurveFittingEdge: public Edge
2  {
3  public:
4      EIGEN_MAKE_ALIGNED_OPERATOR_NEW
5      CurveFittingEdge( double x, double y ): Edge(1,1, std::
        vector<std::string>{"abc"}) {
6          x_ = x;
7          y_ = y;
8      }
9      // 计算曲线模型误差
10     virtual void ComputeResidual() override
11     {
12         Vec3 abc = vertices_[0]->Parameters(); // 估计的参
            数
13         //residual_(0) = std::exp( abc(0)*x_*x_ + abc(1)*x_ +
            abc(2) ) - y_; // 构建残差
14         residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_
            ; // 构建残差

```

```

15     }
16
17     // 计算残差对变量的雅克比
18     virtual void ComputeJacobians() override
19     {
20         Vec3 abc = vertices_[0]->Parameters();
21         double exp_y = std::exp( abc(0)*x_*x_ + abc(1)*x_ +
22                                   abc(2) );
23
24         Eigen::Matrix<double, 1, 3> jaco_abc; // 误差为1维,
25         // 状态量 3 个, 所以是 1x3 的雅克比矩阵
26         //jaco_abc << x_ * x_ * exp_y, x_ * exp_y , 1 * exp_y
27         ;
28         jaco_abc << x_ * x_ , x_ , 1;
29         jacobians_[0] = jaco_abc;
30     }
31     /// 返回边的类型信息
32     virtual std::string TypeInfo() const override { return "
CurveFittingEdge"; }
33
34 public:
35     double x_,y_; // x 值, y 值为 _measurement
36 };

```




图 3: 阻尼因子变化曲线图

1.3 Marquardt 阻尼因子更新策略

Marquardt 阻尼因子更新策略如下:

$$\text{if } \rho < 0.25$$

$$\mu := \mu * 2$$

$$\text{if } \rho > 0.75$$

$$\mu := \mu / 3$$

具体阻尼因子更新策略实现代码为:

```

1  if(rho >= 0 && isfinite(tempChi))
2  {
3      if(rho < 0.25 )
4          currentLambda_*=2;
5      else if(rho >0.75)
6          currentLambda_=currentLambda_/3;
7
8      currentChi_ = tempChi;
9      return true;
10 }
11 else
12 {
13     currentLambda_ =currentLambda_ *2;
```

```

14     return false;
15 }

```

下图为程序运行结果：

```

Test CurveFitting start...
iter: 0 , chi= 36048.3 , Lambda= 0.001
iter: 1 , chi= 16035.7 , Lambda= 349.525
iter: 2 , chi= 8049.31 , Lambda= 2796.2
iter: 3 , chi= 365.103 , Lambda= 932.068
iter: 4 , chi= 118.124 , Lambda= 310.689
iter: 5 , chi= 103.797 , Lambda= 103.563
iter: 6 , chi= 99.7027 , Lambda= 34.521
iter: 7 , chi= 94.7235 , Lambda= 11.507
iter: 8 , chi= 91.8806 , Lambda= 3.83567
iter: 9 , chi= 91.412 , Lambda= 1.27856
iter: 10 , chi= 91.396 , Lambda= 0.426185
iter: 11 , chi= 91.3959 , Lambda= 0.852371
iter: 12 , chi= 91.3959 , Lambda= 1.70474
problem solve cost: 23.395 ms
makeHessian cost: 13.1161 ms
-----After optimization, we got these parameters :
0.941841 2.09467 0.965537
-----ground truth:
1.0, 2.0, 1.0
save mu to txt!

```

图 4: 程序运行结果

2 公式推导

2.1 f_{15}

f_{15} 求的是位移预积分量对 k 时刻角速度 b_k^g 的 Jacobian。

预积分的离散形式，其中积分方法采用中值积分，即两个相邻时刻 k 到 $k+1$ 的位姿是用两个时刻的测量值的平均值来计算。其中位移的预积分量为：

$$\begin{aligned}
 \alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \\
 a &= \frac{1}{2} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a)) \\
 \omega &= \frac{1}{2} ((\omega^{b_k} - b_k^g) + (\omega^{b_{k+1}} - b_k^g)) = \frac{1}{2} (\omega^{b_k} + \omega^{b_{k+1}}) - b_k^g
 \end{aligned} \tag{1}$$

因此位移预积分量也可以写为：

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{4} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a)) \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{4} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a)) \delta t^2
\end{aligned} \tag{2}$$

其中只有括号加号后面一项与角速度 b_k^g 有关，因此 f_{15} 可以变为：

$$\begin{aligned}
f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -\frac{1}{2} \delta b_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_i b_{k+1}} \exp([- \delta b_k^g \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_i b_{k+1}} (I + [- \delta b_k^g \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_i b_{k+1}} [- \delta b_k^g \delta t]_{\times} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= -\frac{1}{4} \frac{\partial R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} \delta t^2 (-\delta b_k^g \delta t)}{\partial \delta b_k^g} \\
&= -\frac{1}{4} R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} \delta t^2 (-\delta t)
\end{aligned} \tag{3}$$

2.2 g_{12}

f_{15} 求的是位移预积分量对 k 时刻角速度的噪声 $n_{b_k^g}$ 的 Jacobian。

将角速度测量噪声也考虑进模型，预积分的离散形式，其中积分方法采用中值积分，即两个相邻时刻 k 到 $k+1$ 的位姿是用两个时刻的测量值的平均值来计算。其中位移的预积分量为：

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \\
a &= \frac{1}{2} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a)) \\
\omega &= \frac{1}{2} ((\omega^{b_k} + n_k^g - b_k^g) + (\omega^{b_{k+1}} + n_{k+1}^g - b_k^g)) = \frac{1}{2} (\omega^{b_k} + n_k^g + \omega^{b_{k+1}} + n_{k+1}^g) - b_k^g
\end{aligned} \tag{4}$$

因此位移预积分量也可以写为：

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{4} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a)) \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{4} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a)) \delta t^2
\end{aligned} \tag{5}$$

其中只有括号加号后面一项与角速度的噪声 $n_{b_k^g}$ 有关, 因此 g_{12} 可以变为:

$$\begin{aligned}
g_{12} &= \frac{\partial \alpha_{b_i b_k}}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ \frac{1}{4} \delta n_{b_k^g} \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} \exp([\frac{1}{2} \delta n_{b_k^g} \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} (I + [\frac{1}{2} \delta n_{b_k^g} \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [\frac{1}{2} \delta n_{b_k^g} \delta t]_{\times} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_{b_k^g}} \\
&= -\frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} (\frac{1}{2} \delta n_{b_k^g} \delta t) \delta t^2}{\partial n_{b_k^g}} \\
&= -\frac{1}{4} R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} (\frac{1}{2} \delta t) \delta t^2
\end{aligned} \tag{6}$$

3 证明

L-M 优化算法中, 引入阻尼因子, 如下式:

$$(J^T J + \mu I) \Delta x_{lm} = -J^T f \tag{7}$$

半正定的信息矩阵 $J^T J$ 特征值 λ_j 和对应的特征向量为 v_j 。对 $J^T J$ 做特征值分解分解后有: $J^T J = V \Lambda V^T$ 。

$J^T J$ 为对称矩阵, 对对称矩阵做特征值分解有 $J^T J = V \Lambda V^T$, 其中 $V^T V = V V^T = I$ 。有 $F' = (J^T f)^T$ 。

证明:

根据 $J^T J = V \Lambda V^T$ 和 $V V^T = I$, $(J^T J + \mu I) \Delta x_{lm} = -J^T f$ 可以写为:

$$\begin{aligned}
(V \Lambda V^T + \mu I) \Delta x_{lm} &= -F'^T \\
(V(\Lambda + \mu I) V^T) \Delta x_{lm} &= -F'^T
\end{aligned} \tag{8}$$

等式两边同时左乘 V^T , 右乘 V , 则有:

$$\begin{aligned}
(\Lambda + \mu I) \Delta x_{lm} &= -V^T F'^T V \\
\Delta x_{lm} &= -\frac{V^T F'^T V}{\Lambda + \mu I}
\end{aligned} \tag{9}$$

其中:

$$V = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix}^T \tag{10}$$

$$\Lambda = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & 0 \\ & & \dots & \\ 0 & & & \lambda_{n-1} \\ & & & & \lambda_n \end{bmatrix} \quad (11)$$

$$\mu I = \begin{bmatrix} \mu & & & \\ & \mu & & 0 \\ & & \dots & \\ 0 & & & \mu \\ & & & & \mu \end{bmatrix} \quad (12)$$

因此变为：

$$\begin{aligned} \Delta x_{lm} = & - \frac{\begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} F'^T \begin{bmatrix} v_1 \\ v_2 \\ \dots \\ v_n \end{bmatrix}}{\begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & 0 \\ & & \dots & \\ 0 & & & \lambda_{n-1} \\ & & & & \lambda_n \end{bmatrix} + \begin{bmatrix} \mu & & & \\ & \mu & & 0 \\ & & \dots & \\ 0 & & & \mu \\ & & & & \mu \end{bmatrix}} \\ = & - \sum_{j=1}^n \frac{v_j^T F'^T v_j}{\lambda_j + \mu} \end{aligned} \quad (13)$$