第三讲-习题

姜帆

2019 年 6 月 29 日

目录

1 LM 算法

1.1 阻尼因子变化曲线图

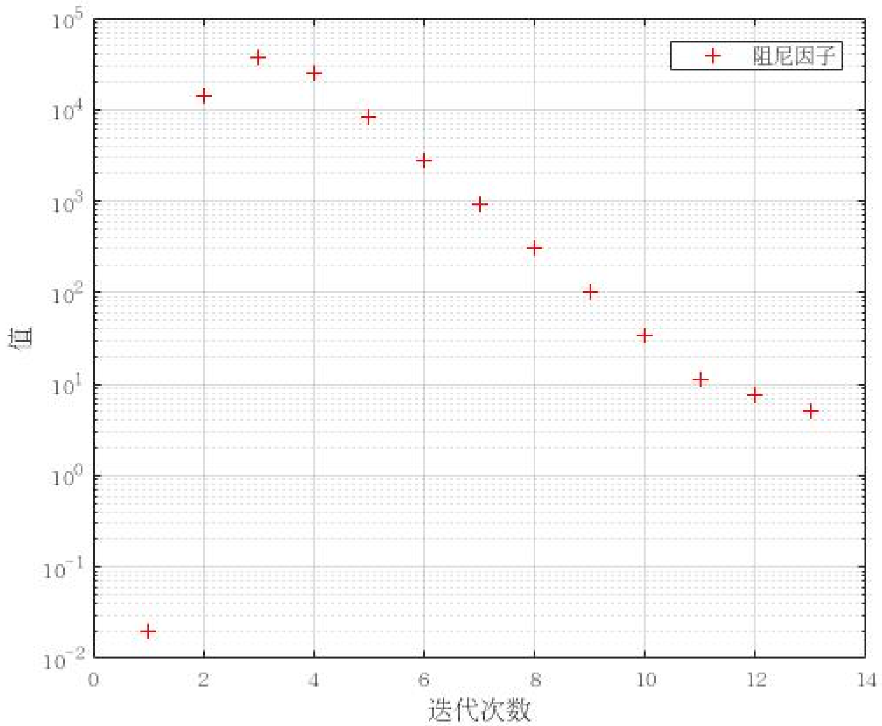

图 1: 阻尼因子变化曲线图

1.2 更改曲线函数

将曲线函数改为 $y = ax^2 + bx + c$，修改对应雅克比计算函数，残差计算函数。另注意由于生成仿真数据时添加了均值为 0，方差为 1 的噪声项，噪声相对于数据较大，因此对增加仿真数据量。 $y = ax^2 + bx + c$ 函数对应的雅克比计算函数（导数）为 $y' = x^2 + x + 1$

```
class CurveFittingEdge: public Edge
{
public:
    EIGEN_MAKE_ALIGNED_OPERATOR_NEW
    CurveFittingEdge( double x, double y ): Edge(1,1, std::
        vector<std::string>{"abc"}) {
        x_ = x;
        y_ = y;
    }
    // 计算曲线模型误差
    virtual void ComputeResidual() override
    {
        Vec3 abc = verticies_[0]->Parameters();  // 估计的参
```

```
数
        //residual_(0) = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) ) - y_;  // 构建残差
        residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_;  // 构建残差
    }

    // 计算残差对变量的雅克比
    virtual void ComputeJacobians() override
    {
        Vec3 abc = verticies_[0]->Parameters();
        double exp_y = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) );

        Eigen::Matrix<double, 1, 3> jaco_abc;  // 误差为1维，状态量 3 个，所以是 1x3 的雅克比矩阵
        //jaco_abc << x_ * x_ * exp_y, x_ * exp_y , 1 * exp_y;
        jaco_abc << x_ * x_ , x_ , 1;
        jacobians_[0] = jaco_abc;
    }
    /// 返回边的类型信息
    virtual std::string TypeInfo() const override { return "CurveFittingEdge"; }
public:
    double x_,y_;  // x 值， y 值为 _measurement
};
```

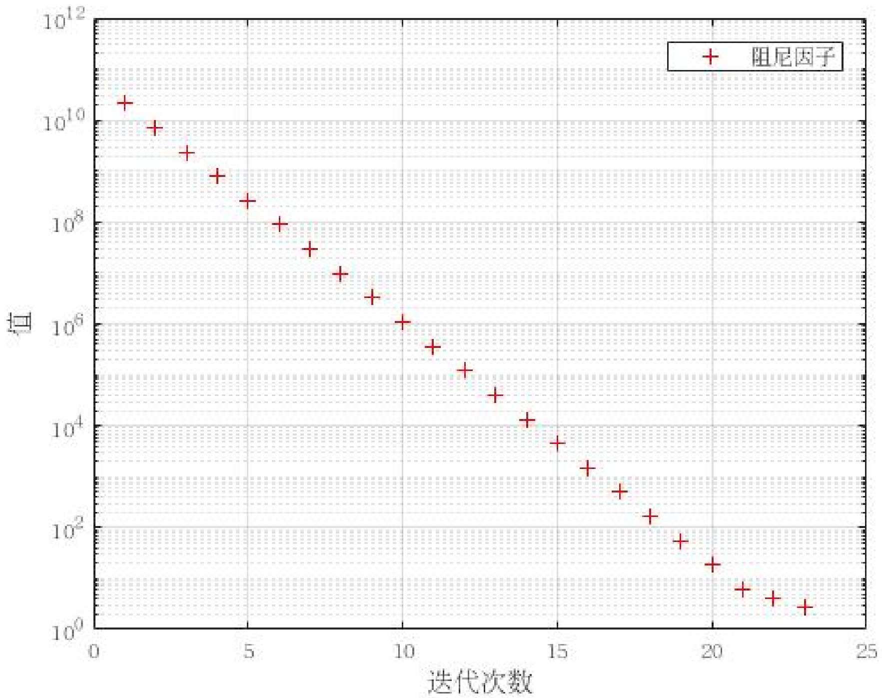

图 2: 阻尼因子变化曲线图

1.3 Marquardt 阻尼因子更新策略

Marquardt 阻尼因子更新策略 [1] if $\rho < 0.25$

2 公式推导

2.1 f_{15}

f_{15} 求的是位移预积分量对 k 时刻角速度 b_k^g 的 Jacobian。

预积分的离散形式，其中积分方法采用中值积分，即两个相邻时刻 k 到 $k+1$ 的位姿是用两个时刻的测量值的平均值来计算。其中位移的预积分量为:

$$\begin{aligned}
&\alpha_{b_i b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{2}a\delta t^2 \\
&a = \frac{1}{2}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_{k+1}}(a^{b_{k+1}} - b_k^a)) \\
&\omega = \frac{1}{2}((\omega^{b_k} - b_k^g) + (\omega^{b_{k+1}} - b_k^g)) = \frac{1}{2}(\omega^{b_k} + \omega^{b_{k+1}}) - b_k^g
\end{aligned} \tag{1}$$

因此位移预积分量也可以写为:

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{2}a\delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{4}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_{k+1}}(a^{b_{k+1}} - b_k^a))\delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{4}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2}\omega\delta t \end{bmatrix}(a^{b_{k+1}} - b_k^a))\delta t^2
\end{aligned} \tag{2}$$

其中只有括号加号后面一项与角速度 b_k^g 有关，因此 f_{15} 可以变为：

$$\begin{aligned}
f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2}\omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -\frac{1}{2}\delta b_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a)\delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} exp([-\delta b_k^g \delta t]_\times)(a^{b_{k+1}} - b_k^a)\delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} (I + [-\delta b_k^g \delta t]_\times)(a^{b_{k+1}} - b_k^a)\delta t^2}{\partial \delta b_k^g} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [-\delta b_k^g \delta t]_\times (a^{b_{k+1}} - b_k^a)\delta t^2}{\partial \delta b_k^g} \\
&= -\frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_\times \delta t^2 (-\delta b_k^g \delta t)}{\partial \delta b_k^g} \\
&= -\frac{1}{4} R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_\times \delta t^2 (-\delta t)
\end{aligned} \tag{3}$$

2.2 g_{12}

f_{15} 求的是位移预积分量对 k 时刻角速度的噪声 $n_{b_k^g}$ 的 Jacobian。

将角速度测量噪声也考虑进模型, 预积分的离散形式，其中积分方法采用中值积分，即两个相邻时刻 k 到 $k+1$ 的位姿是用两个时刻的测量值的平均值来计算。其中位移的预积分量为：

$$\begin{aligned}
&\alpha_{b_i b_{k+1}} = \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{2} a \delta t^2 \\
&a = \frac{1}{2}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_{k+1}}(a^{b_{k+1}} - b_k^a)) \\
&\omega = \frac{1}{2}((\omega^{b_k} + n_k^g - b_k^g) + (\omega^{b_{k+1}} + n_{k+1}^g - b_k^g)) = \frac{1}{2}(\omega^{b_k} + n_k^g + \omega^{b_{k+1}} + n_{k+1}^g) - b_k^g
\end{aligned} \tag{4}$$

因此位移预积分量也可以写为：

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{2} a \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{4}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_{k+1}}(a^{b_{k+1}} - b_k^a))\delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k}\delta t + \frac{1}{4}(q_{b_i b_k}(a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2}\omega \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a))\delta t^2
\end{aligned} \tag{5}$$

其中只有括号加号后面一项与角速度的噪声 $n_{b_k^g}$ 有关，因此 g_{12} 可以变为：

$$
\begin{aligned}
g_{12} &= \frac{\partial \alpha_{b_i b_k}}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2}\omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ \frac{1}{4}\delta n_{b_k^g} \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a)\delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} exp([\frac{1}{2}\delta n_{b_k^g} \delta t]_\times)(a^{b_{k+1}} - b_k^a)\delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} (I + [\frac{1}{2}\delta n_{b_k^g} \delta t]_\times)(a^{b_{k+1}} - b_k^a)\delta t^2}{\partial n_{b_k^g}} \\
&= \frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [\frac{1}{2}\delta n_{b_k^g} \delta t]_\times (a^{b_{k+1}} - b_k^a)\delta t^2}{\partial n_{b_k^g}} \\
&= -\frac{1}{4} \frac{\partial R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_\times (\frac{1}{2}\delta n_{b_k^g} \delta t)\delta t^2}{\partial n_{b_k^g}} \\
&= -\frac{1}{4} R_{b_1 b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_\times (\frac{1}{2}\delta t)\delta t^2
\end{aligned} \tag{6}
$$

3 证明

L-M 优化算法中，引入阻尼因子，如下式：

$$
(J^T J + \mu I)\Delta x_{lm} = -J^T f \tag{7}
$$

半正定的信息矩阵 $J^t J$ 特征值 λ_j 和对应的特征向量为 v_j。对 $J^T J$ 做特征值分解分解后有：$J^T J = V \Lambda V^T$。

$J^T J$ 为对称矩阵，对对称矩阵做特征值分解有 $J^T J = V \Lambda V^T$，其中 $V^T V = V V^T = I$。

有 $F' = (J^T f)^T$。

证明：

根据 $J^T J = V \Lambda V^T$ 和 $V V^T = I$，$(J^T J + \mu I)\Delta x_{lm} = -J^T$ 可以写为：

$$
\begin{aligned}
(V \Lambda V^T + \mu I)\Delta x_{lm} &= -F'^T \\
(V(\Lambda + \mu I)V^T)\Delta x_{lm} &= -F'^T
\end{aligned} \tag{8}
$$

等式两边同时左乘 V^T，右乘 V，则有：

$$
\begin{aligned}
(\Lambda + \mu I)\Delta x_{lm} &= -V^T F'^T V \\
\Delta x_{lm} &= -\frac{V^T F'^T V}{\Lambda + \mu I}
\end{aligned} \tag{9}
$$

其中：

$$
V = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix}^T \tag{10}
$$

$$\Lambda = \begin{bmatrix} \lambda_1 & & & & \\ & \lambda_2 & & \text{\huge0} & \\ & & \dots & & \\ & \text{\huge0} & & \lambda_{n-1} & \\ & & & & \lambda_n \end{bmatrix} \tag{11}$$

$$\mu I = \begin{bmatrix} \mu & & & & \\ & \mu & & \text{\huge0} & \\ & & \dots & & \\ & \text{\huge0} & & \mu & \\ & & & & \mu \end{bmatrix} \tag{12}$$

因此变为:

$$\begin{aligned} \Delta x_{lm} &= -\frac{\begin{bmatrix} v_1 & v_2 & ... & v_n \end{bmatrix} F'^T \begin{bmatrix} v_1 \\ v_2 \\ ... \\ v_n \end{bmatrix}}{\begin{bmatrix} \lambda_1 & & & & \\ & \lambda_2 & & \text{\huge0} & \\ & & \dots & & \\ & \text{\huge0} & & \lambda_{n-1} & \\ & & & & \lambda_n \end{bmatrix} + \begin{bmatrix} \mu & & & & \\ & \mu & & \text{\huge0} & \\ & & \dots & & \\ & \text{\huge0} & & \mu & \\ & & & & \mu \end{bmatrix}} \\ &= -\sum_{i=1}^{n} \frac{v_j^T F'^T v_j}{\lambda_j + \mu} \end{aligned} \tag{13}$$